

Recuperação de Informação para *Product Matching* de Insumos SINAPI

Igor Mundstock Daudt¹

¹Programa de Pós-Graduação em Computação (PPGC)
Instituto de Informática – Universidade Federal do Rio Grande do Sul (UFRGS)
Porto Alegre – RS – Brasil

igor.daudt@ufrgs.br

Abstract. *This work evaluates BM25, dense E5, hybrid E5, and hybrid BGE-M3 for product matching of SINAPI items, using two datasets with distinct lexical profiles: a real ground truth of 852 queries from 948 product-item correlations validated in production, and a synthetic benchmark of 48 queries from technical-notation substitutions. On the real dataset, BM25 attains the highest MAP (0.797), ahead of hybrid BGE-M3 (0.793), with $24\times$ lower latency. On the synthetic one (Jaccard 0.403 vs. 0.652 on the real dataset), the pattern reverses: hybrid BGE-M3 beats BM25 by +0.152 MAP, the largest semantic gain observed. This advantage of dense over lexical retrieval depends on the terminological variation type and does not fully hold on real data.*

Keywords: *information retrieval; product matching; semantic search; hybrid retrieval; SINAPI.*

Resumo. *Este trabalho avalia BM25, E5 denso, E5 hybrid e BGE-M3 hybrid para product matching de insumos do SINAPI, usando dois conjuntos com perfis lexicais distintos: um ground truth real de 852 consultas, de 948 correlações produto-item validadas em uso, e um benchmark sintético de 48 consultas por substituição de notação técnica. No conjunto real, o BM25 obtém o maior MAP (0,797), à frente do BGE-M3 hybrid (0,793), com $24\times$ menos latência. No sintético (Jaccard 0,403 contra 0,652 no real), o padrão se inverte: o BGE-M3 hybrid supera o BM25 em +0,152 de MAP, o maior ganho semântico observado. Essa vantagem do denso sobre o lexical depende do tipo de variação terminológica e não se sustenta em dados reais.*

Palavras-chave: *recuperação de informação; product matching; busca semântica; recuperação híbrida; SINAPI.*

1. Introdução

A recuperação eficiente de informações em bases técnicas é um desafio recorrente em sistemas de apoio à engenharia, compras públicas e orçamentação, agravado pela quantidade de itens e variações terminológicas típicas do domínio da construção civil – um problema próximo ao de *product matching* em catálogos de produtos [Peeters et al. 2020]. No Brasil, o SINAPI é a principal base de referência de custos para obras públicas, mas a busca por itens é dificultada pela distância entre a forma como usuários descrevem produtos e a descrição oficial do catálogo.

Este trabalho avalia métodos lexicais, densos e híbridos de recuperação de informação sobre o catálogo SINAPI usando dois conjuntos de dados com perfis lexicais deliberadamente distintos: (i) um *ground truth* real de 852 consultas, derivadas de 948 correlações produto-item já validadas em uso efetivo de uma plataforma de orçamentação – refletindo como usuários reais descrevem produtos, com vocabulário de fornecedor e abreviações comerciais; e (ii) um *benchmark* sintético controlado de 48 consultas (*ppc_weak*), construído por funções de rotulagem que substituem sistematicamente a notação técnica da descrição oficial (ex. DN em mm $\rightarrow$ polegadas), produzindo baixa sobreposição lexical de forma deliberada. Comparar os dois conjuntos permite testar a hipótese de que *retrievers* densos têm maior vantagem sobre o BM25 quanto maior a variação lexical entre consulta e documento – e verificar se essa vantagem, bem estabelecida para paráfrases semânticas controladas, se sustenta igualmente sobre vocabulário real de produção. Código, dados e resultados agregados estão publicamente disponíveis.¹

2. Materiais e Métodos

Conjunto real. O corpus é composto por 5.813 insumos do catálogo SINAPI de jan/2026. O *ground truth* é formado por 948 correlações reais entre produtos cadastrados por usuários e o item SINAPI correspondente, já validadas como parte do uso operacional da ferramenta (geradas por consultas reais na plataforma PainelConstru [PainelConstru 2026], *marketplace* de construção). Agrupadas por par consulta-insumo, essas correlações formam 852 consultas de avaliação, cada uma com um ou mais insumos relevantes.

Conjunto sintético controlado (*ppc_weak*). Um segundo corpus, de 4.851 itens do catálogo SINAPI, serve de base a um *benchmark* de 48 consultas sobre 16 itens, construído por funções de rotulagem que substituem sistematicamente a notação técnica da descrição oficial (ex. DN em mm $\rightarrow$ polegadas; remoção do termo “soldável”/“roscável”), produzindo consultas com Jaccard deliberadamente baixo em relação ao item-alvo. Por usar numeração de item independente da do conjunto real, os dois conjuntos são avaliados separadamente, cada um sobre seu corpus nativo, e comparados no nível de métricas agregadas.

Métodos. Foram avaliados quatro métodos, implementados localmente e sem servidor externo: BM25 [Robertson and Zaragoza 2009] ($k_1 = 1,2$, $b = 0,75$); E5 *multilingual* denso [Wang et al. 2022] (*multilingual-e5-small*, 384 dim.); E5 *hybrid* (E5 + BM25 via *Reciprocal Rank Fusion*, RRF [Cormack et al. 2009], $k = 60$); e BGE-M3 *hybrid* [Chen et al. 2024] (*bge-m3*, 1024 dim. + BM25 via RRF). Cada consulta retornou até 100 candidatos; o *cache* de *embeddings* do BGE-M3 foi pré-computado e validado contra cada corpus. Hardware: CPU Intel i7-10610U, 4 núcleos, sem GPU. As métricas de qualidade (MAP e NDCG@10/@100) são calculadas por consulta e macro-agregadas, sendo invariantes à escala absoluta dos scores de cada método. Adicionalmente, calculou-se a similaridade de Jaccard (interseção/união de tokens) entre cada consulta e a descrição do item-alvo, nos dois conjuntos.

¹https://github.com/igordaudt/Prod_Match_Eramia_26

3. Resultados

A Tabela 1 apresenta os resultados sobre as 852 consultas do conjunto real (*limit* = 100). O BM25 obtém o maior MAP (0,7967), à frente do BGE-M3 hybrid (0,7932) – diferença de apenas 0,0035 – com latência 24 vezes menor (15,9 ms vs. 378,6 ms).

Tabela 1. Retrieval sobre o conjunto real (852 consultas, limit=100)

Método	MAP	R@10	R@100	Tempo (ms)
BM25	0,7967	0,9726	0,9988	15,9
BGE-M3 hybrid	0,7932	0,9767	1,0000	378,6
E5 hybrid	0,7638	0,9705	0,9977	48,7
E5 (denso)	0,7116	0,9417	0,9930	283,3

A Tabela 2 confronta esse resultado com o do *ppc_weak* e com quartis de Jaccard dentro do conjunto real. O Jaccard médio do conjunto real (0,649) é bem mais alto que o do *ppc_weak* (0,403). No *ppc_weak*, o BGE-M3 hybrid supera o BM25 em +0,152 de MAP – a maior vantagem semântica do estudo; no conjunto real, essa vantagem desaparece (BM25 0,797 vs. BGE-M3 hybrid 0,793). Dentro do conjunto real, porém, a relação entre Jaccard e vantagem semântica é fraca e não monótona (Spearman $\approx -0,07$; o quartil Q3, não o de menor Jaccard, tem o maior MAP) – Jaccard baixo em dados reais tem causas heterogêneas (abreviações, códigos internos, erros de correlação), nem todas resolúveis por um *embedding* genérico.

Tabela 2. Jaccard médio $\times$ MAP por método, nos dois conjuntos

Conjunto	N	Jaccard	BM25	BGE-M3 h.
Sintético (<i>ppc_weak</i>)	48	0,403	0,559	0,711
Real – Q1 (menor Jaccard)	218	0,285	0,709	0,714
Real – Q2	222	0,670	0,776	0,782
Real – Q3	202	0,793	0,886	0,866
Real – Q4 (maior Jaccard)	210	0,866	0,823	0,818
Real – geral	852	0,649	0,797	0,793

O BGE-M3 denso puro, avaliado apenas no conjunto sintético, obtém ali MAP= 0,723 – o maior valor entre os cinco métodos. Uma modelagem de tópicos complementar (BERTopic) identificou 90 tópicos no corpus real: a vantagem do BM25 se concentra em famílias com terminologia técnica exata, e o BGE-M3 hybrid vence em famílias com maior variação comercial – o efeito não é uniforme.

Divisão por mediana de Jaccard. Para testar a hipótese de forma mais direta, uniu-se os dois conjuntos numa base combinada de 900 consultas (852 reais + 48 sintéticas, itens deduplicados por descrição) e dividiu-se pela mediana de Jaccard (0,754) em duas metades (Tabela 3). A vantagem semântica (MAP BGE-M3 hybrid – MAP BM25) é positiva na metade inferior (+0,023) e negativa na superior (−0,013) – **hipótese confirmada**, com efeito modesto (a metade superior é quase só consultas reais, 448 de 450).

Confirmação por NDCG. Para verificar se o padrão depende da métrica, recalculou-se o NDCG por consulta (relevância binária, desconto logarítmico por posição,

Tabela 3. MAP por metade de Jaccard (900 consultas combinadas)

Metade	Jaccard	BM25	BGE-M3 h.	Vant. sem.
Inferior ($< 0,754$)	0,447	0,7165	0,7396	+0,023
Superior ($\geq 0,754$)	0,825	0,8516	0,8382	-0,013

normalizado pelo DCG ideal da própria consulta) e macro-agregou-se por metade (Tabela 4) – mesma lógica de agregação do MAP, invariante à escala absoluta do score. O NDCG reproduz o mesmo cruzamento nos dois cortes: o BGE-M3 hybrid lidera na metade de menor Jaccard e o BM25 o ultrapassa na de maior, com amplitude equivalente ($\approx 0,029$ contra $0,036$ do MAP). Duas métricas de ranqueamento independentes apontando o mesmo cruzamento indicam que o efeito não é artefato da métrica escolhida. Vale notar que essa robustez depende de a métrica ser calculada *por consulta*: curvas Precisão $\times$ Recall agregadas por um limiar de score global misturam consultas cujos scores não são comparáveis entre si e penalizam sistematicamente métodos lexicais de score bruto como o BM25 – por isso não são usadas aqui para comparar métodos.

Tabela 4. NDCG por metade de Jaccard (900 consultas combinadas)

Métrica	Metade	BM25	E5	E5 h.	BGE-M3 h.	Vant. sem.
NDCG@10	Inferior	0,7769	0,7323	0,7816	0,7962	+0,019
NDCG@10	Superior	0,8914	0,7993	0,8485	0,8813	-0,010
NDCG@100	Inferior	0,7891	0,7492	0,7936	0,8082	+0,019
NDCG@100	Superior	0,8921	0,8072	0,8496	0,8821	-0,010

4. Discussão e Conclusão

O achado central é que a vantagem de *retrievers* densos sobre o lexical – clara no conjunto sintético e confirmada, por MAP e NDCG, pela divisão por mediana de Jaccard – não se sustenta integralmente no conjunto real: baixa sobreposição lexical é condição necessária, mas não suficiente, dependendo também do tipo de divergência terminológica. Para *product matching* sobre catálogos técnicos brasileiros, o BM25 continua um *baseline* forte e barato; a escolha de *retriever* em produção deveria ser validada sobre consultas reais dos próprios usuários, não só sobre *benchmarks* sintéticos.

Como limitações: o BGE-M3 denso puro não foi avaliado sobre o conjunto real; as diferenças de MAP/NDCG e a divisão por mediana carecem de teste de significância estatística formal; a metade superior de Jaccard é composta quase só por consultas reais (448/450); o *ground truth* é de relevância binária, não graduados; e as correlações reais (subproduto do uso da plataforma), não foram auditadas especificamente para este experimento. Trabalhos futuros: BGE-M3 denso sobre o conjunto real, *bootstrap* pareado sobre a diferença de vantagem semântica entre metades, e ampliação do conjunto sintético para outras classes de variação (ex: normas, pressão, bitolas).

Referências

Chen, J., Xiao, S., Zhang, P., Luo, K., Lian, D., and Liu, Z. (2024). BGE M3-embedding: Multi-lingual, multi-functionality, multi-granularity text embeddings through self-knowledge distillation. arXiv preprint arXiv:2402.03216.

- Cormack, G. V., Clarke, C. L. A., and Buettcher, S. (2009). Reciprocal rank fusion outperforms condorcet and individual rank learning methods. In *Proceedings of the 32nd International ACM SIGIR Conference on Research and Development in Information Retrieval (SIGIR'09)*, pages 758–759, New York. ACM.
- PainelConstru (2026). PainelConstru: plataforma de orçamentação e *marketplace* para a construção civil. <https://www.painelconstru.com.br>. Acesso em: 5 set. 2026.
- Peeters, R., Bizer, C., and Glavaš, G. (2020). Intermediate training of BERT for product matching. In *Proceedings of the 2nd International Workshop on Challenges and Experiences from Data Integration to Knowledge Graphs (DI2KG 2020)*, volume 2726 of *CEUR Workshop Proceedings*.
- Robertson, S. and Zaragoza, H. (2009). The probabilistic relevance framework: BM25 and beyond. *Foundations and Trends in Information Retrieval*, 3(4):333–389.
- Wang, L., Yang, N., Huang, X., Jiao, B., Yang, L., Jiang, D., Majumder, R., and Wei, F. (2022). Text embeddings by weakly-supervised contrastive pre-training. arXiv preprint arXiv:2212.03533.