

Recuperação de Informação para *Product Matching* de Insumos SINAPI

Igor Daudt¹

¹Programa de Pós-Graduação em Computação (PPGC)

igor.daudt@ufrgs.br

Abstract. *This work evaluates information retrieval methods (BM25, dense E5, hybrid E5, and hybrid BGE-M3) for product matching of SINAPI technical items, using two datasets with deliberately distinct lexical profiles: a real ground truth of 852 queries derived from 948 product-item correlations already validated in production use of a budgeting platform, and a controlled synthetic benchmark of 48 queries built from systematic technical-notation substitutions. On the real dataset, BM25 achieves the highest MAP (0.797), ahead of hybrid BGE-M3 (0.793), with 24 times lower latency. On the synthetic dataset, built for deliberately low lexical overlap (Jaccard 0.403 vs. 0.652 on the real one), the pattern reverses: hybrid BGE-M3 beats BM25 by +0.152 MAP, the largest semantic advantage observed. The advantage of dense retrievers over lexical ones depends on the type of terminological variation and does not fully hold on real production data.*

Keywords: *information retrieval; product matching; semantic search; hybrid retrieval; SINAPI.*

Resumo. *Este trabalho avalia métodos de recuperação de informação (BM25, E5 denso, E5 híbrido e BGE-M3 híbrido) para product matching de insumos do SINAPI, usando dois conjuntos de dados com perfis lexicais deliberadamente distintos: um ground truth real de 852 consultas, derivadas de 948 correlações produto-item já validadas em uso efetivo de uma plataforma de orçamentação, e um benchmark sintético controlado de 48 consultas, construído por substituições sistemáticas de notação técnica. No conjunto real, o BM25 obtém o maior MAP (0,797), à frente do BGE-M3 híbrido (0,793), com 24 vezes menos latência. No conjunto sintético, construído para ter baixa sobreposição lexical deliberada (Jaccard 0,403 contra 0,652 no conjunto real), o padrão se inverte: o BGE-M3 híbrido supera o BM25 em +0,152 de MAP, a maior vantagem semântica observada. A vantagem de retrievers densos sobre o lexical depende do tipo de variação terminológica e não se sustenta integralmente em documentos com maior similaridade lexical.*

Palavras-chave: *recuperação de informação; product matching; busca semântica; recuperação híbrida; SINAPI.*

1. Introdução

A recuperação eficiente de informações em bases técnicas é um desafio recorrente em sistemas de apoio à engenharia, compras públicas e orçamentação, agravado pela quantidade de itens e variações terminológicas típicas do domínio da construção civil – um problema

próximo ao de *product matching* em catálogos de produtos [Peeters et al. 2020]. No Brasil, o SINAPI é a principal base de referência de custos para obras públicas, mas a busca por itens é dificultada pela distância entre a forma como usuários descrevem produtos e a descrição oficial do catálogo.

Este trabalho avalia métodos lexicais, densos e híbridos de recuperação de informação sobre o catálogo SINAPI usando dois conjuntos de dados com perfis lexicais deliberadamente distintos: (i) um *ground truth* real de 852 consultas, derivadas de 948 correlações produto-item já validadas em uso efetivo de uma plataforma de orçamentação – refletindo como usuários reais descrevem produtos, com vocabulário de fornecedor e abreviações comerciais; e (ii) um *benchmark* sintético controlado de 48 consultas (*ppc_weak*), construído por funções de rotulagem que substituem sistematicamente a notação técnica da descrição oficial (ex. DN em mm $\rightarrow$ polegadas), produzindo baixa sobreposição lexical de forma deliberada. Comparar os dois conjuntos permite testar a hipótese de que *retrievers* densos têm maior vantagem sobre o BM25 quanto maior a variação lexical entre consulta e documento – e verificar se essa vantagem, bem estabelecida para paráfrases semânticas controladas, se sustenta igualmente sobre vocabulário real de produção. Código, dados e resultados agregados estão publicamente disponíveis.¹

2. Materiais e Métodos

Conjunto real. O corpus é composto por 5.813 insumos do catálogo SINAPI de jan/2026. O *ground truth* é formado por 948 correlações reais entre produtos cadastrados por usuários e o item SINAPI correspondente, já validadas como parte do uso operacional da ferramenta (geradas por consultas reais na plataforma Paine!Constru [Paine!Constru 2026], *marketplace* de construção). Agrupadas por par consulta-insumo, essas correlações formam 852 consultas de avaliação, cada uma com um ou mais insumos relevantes.

Conjunto sintético controlado (*ppc_weak*). Um segundo corpus, de 4.851 itens do catálogo SINAPI, serve de base a um *benchmark* de 48 consultas sobre 16 itens, construído por funções de rotulagem que substituem sistematicamente a notação técnica da descrição oficial (ex. DN em mm $\rightarrow$ polegadas; remoção do termo “soldável”/“rosçável”), produzindo consultas com Jaccard deliberadamente baixo em relação ao item-alvo. Por usar numeração de item independente da do conjunto real, os dois conjuntos são avaliados separadamente, cada um sobre seu corpus nativo, e comparados no nível de métricas agregadas.

Métodos. Foram avaliados quatro métodos, implementados localmente e sem servidor externo: BM25 [Robertson and Zaragoza 2009] ($k_1 = 1,2$, $b = 0,75$); E5 *multilingual* denso [Wang et al. 2022] (*multilingual-e5-small*, 384 dim.); E5 *hybrid* (E5 + BM25 via *Reciprocal Rank Fusion*, RRF [Cormack et al. 2009], $k = 60$); e BGE-M3 *hybrid* [Chen et al. 2024] (*bge-m3*, 1024 dim. + BM25 via RRF). Cada consulta retornou até 100 candidatos; o *cache* de *embeddings* do BGE-M3 foi pré-computado e validado contra cada corpus. Hardware: CPU Intel i7-10610U, 4 núcleos, sem GPU. As métricas de qualidade (MAP e NDCG@10/@100) são calculadas por consulta e macro-agregadas, sendo invariantes à escala absoluta dos scores de cada método. Adicional-

¹https://github.com/igordaudt/Prod_Match_Eramia_26

mente, calculou-se a similaridade de Jaccard (interseção/união de tokens) entre cada consulta e a descrição do item-alvo, nos dois conjuntos.

3. Resultados

A Tabela 1 apresenta os resultados sobre as 852 consultas do conjunto real (*limit* = 100). O BM25 obtém o maior MAP (0,7967), à frente do BGE-M3 hybrid (0,7932) – diferença de apenas 0,0035 – com latência 24 vezes menor (15,9 ms vs. 378,6 ms).

Tabela 1. Retrieval sobre o conjunto real (852 consultas, limit=100)

Método	MAP	R@10	R@100	Tempo (ms)
BM25	0,7967	0,9726	0,9988	15,9
BGE-M3 hybrid	0,7932	0,9767	1,0000	378,6
E5 hybrid	0,7638	0,9705	0,9977	48,7
E5 (denso)	0,7116	0,9417	0,9930	283,3

A Tabela 2 confronta esse resultado com o do *ppc_weak* e com quartis de Jaccard dentro do conjunto real. O Jaccard médio do conjunto real (0,649) é bem mais alto que o do *ppc_weak* (0,403). No *ppc_weak*, o BGE-M3 hybrid supera o BM25 em +0,152 de MAP – a maior vantagem semântica do estudo; no conjunto real, essa vantagem desaparece (BM25 0,797 vs. BGE-M3 hybrid 0,793). Dentro do conjunto real, porém, a relação entre Jaccard e vantagem semântica é fraca e não monótona (Spearman $\approx -0,07$; o quartil Q3, não o de menor Jaccard, tem o maior MAP) – Jaccard baixo em dados reais tem causas heterogêneas (abreviações, códigos internos, erros de correlação), nem todas resolúveis por um *embedding* genérico.

Tabela 2. Jaccard médio $\times$ MAP por método, nos dois conjuntos

Conjunto	N	Jaccard	BM25	BGE-M3 h.
Sintético (ppc_weak)	48	0,403	0,559	0,711
Real – Q1 (menor Jaccard)	218	0,285	0,709	0,714
Real – Q2	222	0,670	0,776	0,782
Real – Q3	202	0,793	0,886	0,866
Real – Q4 (maior Jaccard)	210	0,866	0,823	0,818
Real – geral	852	0,649	0,797	0,793

O BGE-M3 denso puro, avaliado apenas no conjunto sintético, obtém ali MAP= 0,723 – o maior valor entre os cinco métodos. Uma modelagem de tópicos complementar (BERTopic) identificou 90 tópicos no corpus real: a vantagem do BM25 se concentra em famílias com terminologia técnica exata, e o BGE-M3 hybrid vence em famílias com maior variação comercial – o efeito não é uniforme.

Divisão por mediana de Jaccard. Para testar a hipótese de forma mais direta, uniu-se os dois conjuntos numa base combinada de 900 consultas (852 reais + 48 sintéticas, itens deduplicados por descrição) e dividiu-se pela mediana de Jaccard (0,754) em duas metades (Tabela 3). A vantagem semântica (MAP BGE-M3 hybrid – MAP BM25) é positiva na metade inferior (+0,023) e negativa na superior (−0,013) – **hipótese confirmada**, com efeito modesto (a metade superior é quase só consultas reais, 448 de 450).

Tabela 3. MAP por metade de Jaccard (900 consultas combinadas)

Metade	Jaccard	BM25	BGE-M3 h.	Vant. sem.
Inferior ($< 0,754$)	0,447	0,7165	0,7396	+0,023
Superior ($\geq 0,754$)	0,825	0,8516	0,8382	-0,013

Confirmação por NDCG. Para verificar se o padrão depende da métrica, recalculou-se o NDCG por consulta (relevância binária, desconto logarítmico por posição, normalizado pelo DCG ideal da própria consulta) e macro-agregou-se por metade (Tabela 4) – mesma lógica de agregação do MAP, invariante à escala absoluta do score. O NDCG reproduz o mesmo cruzamento nos dois cortes: o BGE-M3 hybrid lidera na metade de menor Jaccard e o BM25 o ultrapassa na de maior, com amplitude equivalente ($\approx 0,029$ contra 0,036 do MAP). Duas métricas de ranqueamento independentes apontando o mesmo cruzamento indicam que o efeito não é artefato da métrica escolhida. Vale notar que essa robustez depende de a métrica ser calculada *por consulta*: curvas Precisão×Recall agregadas por um limiar de score global misturam consultas cujos scores não são comparáveis entre si e penalizam sistematicamente métodos lexicais de score bruto como o BM25 – por isso não são usadas aqui para comparar métodos.

Tabela 4. NDCG por metade de Jaccard (900 consultas combinadas)

Métrica	Metade	BM25	E5	E5 h.	BGE-M3 h.	Vant. sem.
NDCG@10	Inferior	0,7769	0,7323	0,7816	0,7962	+0,019
NDCG@10	Superior	0,8914	0,7993	0,8485	0,8813	-0,010
NDCG@100	Inferior	0,7891	0,7492	0,7936	0,8082	+0,019
NDCG@100	Superior	0,8921	0,8072	0,8496	0,8821	-0,010

4. Discussão e Conclusão

O achado central é que a vantagem de *retrievers* densos sobre o lexical – clara no conjunto sintético e confirmada, por MAP e NDCG, pela divisão por mediana de Jaccard – não se sustenta integralmente no conjunto real: baixa sobreposição lexical é condição necessária, mas não suficiente, dependendo também do tipo de divergência terminológica. Para *product matching* sobre catálogos técnicos brasileiros, o BM25 continua um *baseline* forte e barato; a escolha de *retriever* em produção deveria ser validada sobre consultas reais dos próprios usuários, não só sobre *benchmarks* sintéticos.

Como limitações: o BGE-M3 denso puro não foi avaliado sobre o conjunto real; as diferenças de MAP/NDCG e a divisão por mediana carecem de teste de significância estatística formal; a metade superior de Jaccard é composta quase só por consultas reais (448/450); o *ground truth* é de relevância binária, não graduados; e as correlações reais (subproduto do uso da plataforma), não foram auditadas especificamente para este experimento. Trabalhos futuros: BGE-M3 denso sobre o conjunto real, *bootstrap* pareado sobre a diferença de vantagem semântica entre metades, e ampliação do conjunto sintético para outras classes de variação (ex: normas, pressão, bitolas).

Referências

- Chen, J., Xiao, S., Zhang, P., Luo, K., Lian, D., and Liu, Z. (2024). BGE M3-embedding: Multi-lingual, multi-functionality, multi-granularity text embeddings through self-knowledge distillation. arXiv preprint arXiv:2402.03216.
- Cormack, G. V., Clarke, C. L. A., and Buettcher, S. (2009). Reciprocal rank fusion outperforms condorcet and individual rank learning methods. In *Proceedings of the 32nd International ACM SIGIR Conference on Research and Development in Information Retrieval (SIGIR'09)*, pages 758–759, New York. ACM.
- PainelConstru (2026). PainelConstru: plataforma de orçamentação e *marketplace* para a construção civil. <https://www.painelconstru.com.br>. Acesso em: 5 set. 2026.
- Peeters, R., Bizer, C., and Glavaš, G. (2020). Intermediate training of BERT for product matching. In *Proceedings of the 2nd International Workshop on Challenges and Experiences from Data Integration to Knowledge Graphs (DI2KG 2020)*, volume 2726 of *CEUR Workshop Proceedings*.
- Robertson, S. and Zaragoza, H. (2009). The probabilistic relevance framework: BM25 and beyond. *Foundations and Trends in Information Retrieval*, 3(4):333–389.
- Wang, L., Yang, N., Huang, X., Jiao, B., Yang, L., Jiang, D., Majumder, R., and Wei, F. (2022). Text embeddings by weakly-supervised contrastive pre-training. arXiv preprint arXiv:2212.03533.